



AgentOps

정원국

텔러스 AI 대표

저작권 안내

(주)업스테이지가 제공하는 모든 교육 콘텐츠의 지식재산권은

운영 주체인 (주)업스테이지 또는 해당 저작물의 적법한 관리자에게 귀속되어 있습니다.

콘텐츠 일부 또는 전부를 복사, 복제, 판매, 재판매 공개, 공유 등을 할 수 없습니다.

유출될 경우 지식재산권 침해에 대한 책임을 부담할 수 있습니다.

유출에 해당하여 금지되는 행위의 예시는 다음과 같습니다.

- 콘텐츠를 재가공하여 온/오프라인으로 공개하는 행위
- 콘텐츠의 일부 또는 전부를 이용하여 인쇄물을 만드는 행위
- 콘텐츠의 전부 또는 일부를 녹취 또는 녹화하거나 녹취록을 작성하는 행위
- 콘텐츠의 전부 또는 일부를 스크린 캡처하거나 카메라로 촬영하는 행위
- 지인을 포함한 제3자에게 콘텐츠의 일부 또는 전부를 공유하는 행위
- 다른 정보와 결합하여 Upstage Education의 콘텐츠임을 알아볼 수 있는 저작물을 작성, 공개하는 행위
- 제공된 데이터의 일부 혹은 전부를 Upstage Education 프로젝트/실습 수행 이외의 목적으로 사용하는 행위

01

AgentOps

Agent를 잘 운영하기 위한 접근 방식인 AgentOps에 대해 설명합니다.

AgentOps

Operations

- **DevOps (Development and Operations)**
 - 결정론적 소프트웨어 애플리케이션
- **MLOps (Machine Learning Operations)**
 - DevOps + ML (Output이 비결정론적, Input에 의존)
- **FMOps(Foundation Model Operations)**
 - 사전 훈련 또는 파인튜닝 파운데이션 모델의 제품화
- **PromptOps(Prompt and Operations)**
 - 저장소, 계보, 메타데이터 관리 등 프롬프트 운영
- **RAGOps(RAG and Operations)**
 - 오프라인 데이터, 검색, 증강 생성 등의 RAG 솔루션




Figure 1. Relationship between DevOps, MLOps, and AgentOps.¹³

[1] <https://www.kaggle.com/whitepaper-agent-companion>

AgentOps

Operations

Ops는 사람, 프로세스, 기술의 효과적인 조합을 의미합니다.

단순히 기술이 아니라 고객의 운영 모델, 기존 사업부, 전체 조직 구조 등을 모두 고려한 접근 방식입니다.

- **AgentOps(Agent and Operations)**

- 내부 및 외부 도구 관리
- 에이전트 두뇌 프롬프트
- 오케스트레이션
- 메모리
- 작업 분해 (Goal Decomposition) etc




Figure 2. Each of these “Ops” are about technology, processes, and people^[2]

AgentOps

Agent Lifecycle

- **Development**
 - 구체적인 목표, 제약 조건, 다양한 종속성과, 데이터 파이프라인 설계
- **Testing**
 - 시뮬레이션된 “샌드박스” 환경에서 에이전트의 성능 평가
- **Monitoring**
 - 배포 이후 Session, Trace, Span 수준에서의 에이전트 성능 평가
- **Feedback**
 - 피드백을 기록할 수 있는 도구와 성능 향상 메커니즘
- **Governance**
 - 윤리적 행동 제약과 관련한 가드레일과 정책들

Cost Optimization

효과적인 Agent 서비스 운영을 위한 방안에 대해 설명합니다.

Cost Optimization

KV-Cache


KV Cache는 LLM이 텍스트를 생성하는 과정에서, 이미 처리된 이전 토큰들의 Key와 Value 벡터들을 메모리에 저장해두고 재사용하는 기술입니다.

- **Autoregressive Model**

- N 번째 토큰을 생성 하기 위해 1 부터 N-1 번째까지의 모든 토큰과의 관계를 계산합니다.

- **KV-Cache**

- 1 부터 N-1 번째까지의 모든 토큰과의 관계를 계산한 것을 저장해둡니다.




Cost Optimization

Design Around the KV-Cache

Design Around the KV-Cache

[4]




Cost Optimization

Design Around the KV-Cache

[4]

Design Around the KV-Cache




Cost Optimization

Design Around the KV-Cache

Design Around the KV-Cache

[4]



Cost Optimization


Design Around the KV-Cache

Cache Hit는 지연 시간과 비용 두 가지 핵심 문제를 동시에 해결하는 열쇠입니다.

- 구조적 측면
 - Input : Output = 100 : 1 (in Manus)
- 사용자 경험 측면
 - TTFT (Time To First Token)
- 비용적 측면
 - Cache Miss \$5/MTok
 - Cache Hit \$0.5/MTok (Opus4.5 기준)

Design Around the KV-Cache


[4]



Cost Optimization

Prompt Caching is All You Need


- OpenAI의 경우, 최근 같은 프롬프트를 처리한 서버로 API 요청을 자동 라우팅합니다.
- Claude의 경우, 5분 / 1시간 캐시 콘텐츠 사용 비용을 내면 캐시가 갱신됩니다.



Cost Optimization

Prompt Caching is All You Need

- 프롬프트 접두사 유지
- 리듀서 패턴의 컨텍스트
- 캐시 체크포인트 필요 여부 (ex. AWS BedRock)
- 최소 토큰 요구 여부 (ex. Claude, OpenAI)




Best Practices

Agentic Workflow 설계를 위한 실무적인 팁을 소개합니다.

Best Practices

1. Context Compaction and Summarization


Prevent Context Rot



[6]


Best Practices

2. Share Context by communicating, not communicate by sharing context




Best Practices

3. Keep the model's toolset small



Best Practices

4. Treat "Agent as Tool" with Structured Schemas



[9]



Building intelligence for the future of work